

Санкт-Петербургский государственный университет

Группа 20Б.09-мм

БАРУТКИН Илья Дмитриевич

Визуализация результатов поиска примитивов в веб-приложении Desbordante

Отчёт по учебной практике

Научный руководитель:
ассистент кафедры ИАС Г.А. Чернышев

Санкт-Петербург
2022

Оглавление

Введение	3
1. Постановка задачи	4
1.1. Цель работы	4
1.2. Требования к приложению	4
2. Обзор существующих решений	6
2.1. Metanome	6
2.2. Desbordante	6
3. Реализация	8
3.1. Используемые технологии	8
3.2. Формула веса атрибута	8
3.3. Страница	8
3.4. Контекст	9
3.5. Жизненный цикл	9
3.6. Диаграммы	10
4. Тестирование	12
Заключение	13
Список литературы	14

Введение

Профилирование данных [1] — это процесс извлечения метаданных из данных. Метаданные — это, к примеру, размер файла, время создания, авторство. Но это также и любые закономерности, сокрытые в данных. Закономерности, которые могут присутствовать в данных, описываются с помощью различных примитивов. Примитив — это некоторое правило, действующее над данными (или их частью), описанное математическими методами.

Поскольку инструменты профилирования данных в основном нацелены на пользователей, эффективная визуализация результатов имеет первостепенное значение. Только тогда пользователи смогут интерпретировать результаты и реагировать на них [1].

В предыдущей работе [3] была описана разработка новой версии веб-приложения для платформы Desbordante, высокопроизводительного профайлера данных. В приложении уже присутствовала визуализация результатов поиска примитивов в виде списка зависимостей с возможностью фильтрации по атрибутам и сортировки. Однако для удобства анализа результатов в приложении требовался иной подход, который бы позволил оценивать значимость различных атрибутов в множестве зависимостей. В предыдущей версии веб-приложения уже была разработана страница, реализующая такой подход. Она визуализирует результаты поиска примитивов “функциональная зависимость” и “условная функциональная зависимость” в виде диаграмм. Требовалось разработать аналогичный функционал в новой версии веб-приложения, учитывая изменения в дизайне.

1. Постановка задачи

1.1. Цель работы

Целью работы является реализация страницы, визуализирующей результаты поиска примитивов “функциональная зависимость” и “условная функциональная зависимость” в виде диаграмм, в рамках разрабатываемой версии веб-приложения Desbordante. Для её выполнения были поставлены следующие задачи:

1. сверстать макеты приложения
2. реализовать отдельные компоненты, необходимые для страницы
3. реализовать взаимодействие с серверной частью приложения и отображение получаемых данных
4. проверить работоспособность приложения

1.2. Требования к приложению

Были поставлены следующие требования к странице, визуализирующей результаты поиска примитивов. Оно должно позволять пользователю

1. просматривать две диаграммы: с атрибутами левой стороны зависимостей и с атрибутами правой стороны зависимостей
2. фильтровать атрибуты по названию
3. просматривать диаграммы по слоям, ограничивая количество показываемых секторов диаграммы в одном слое
4. выбирать атрибуты по нажатию на сектор на диаграмме для последующей фильтрации страницы со списком зависимостей
5. исследовать результаты выполнения задач на поиск двух видов примитивов

- функциональные зависимости
- условные функциональные зависимости

2. Обзор существующих решений

2.1. Metanome

Metanome — совместный проект Hasso Plattner Institute и Qatar Computing Research Institute. Это открытая платформа для профилирования данных, реализованная на языке Java. Она поддерживает различные методы визуализации результатов, такие как диаграмма солнечных лучей и префиксное дерево атрибутов [6].




Рис. 1: Диаграмма солнечных лучей, реализованная в платформе Metanome

2.2. Desbordante

Desbordante реализовывалась как альтернатива платформе Metanome. По сравнению с ней Desbordante работает быстрее и требует меньше памяти, в среднем в два раза [5]. Веб-интерфейс инструмента позволяет визуализировать результаты поиска примитивов “функциональная за-

зависимость” и “условная функциональная зависимость” в виде диаграмм. Каждый атрибут представляется в виде сектора размера, соответствующего общей ценности атрибута.

3. Реализация

3.1. Используемые технологии

Проект разрабатывается на языке TypeScript с помощью фреймворков React и Next.js. Также используются специальные библиотеки для взаимодействия с GraphQL API и линтер [3].

Для создания диаграмм в ранней версии проекта [4] был сделан выбор в пользу Chart.js — наиболее популярной javascript-библиотеки для создания графиков и диаграмм. Для отрисовки используется HTML-элемент canvas. Для того, чтобы интегрировать функционал данной библиотеки в React-приложение на языке TypeScript была дополнительно использована библиотека react-chartjs-2. Она позволяет использовать диаграммы как любые другие React-компоненты и имеет полностью типизированный интерфейс [2].

3.2. Формула веса атрибута

Для определения веса атрибута в приложении использовалась следующая формула.

$$S(A) = \sum_f \frac{\sigma(f, A)}{|f|_l} \text{ где } f \text{ — зависимость,}$$
$$\sigma(f, A) = \begin{cases} 1 & \text{А присутствует в левой (правой) части } f \\ 0 & \text{иначе} \end{cases},$$

$|f|_l$ — длина левой (правой) части f

В ранней работе [4] был обоснован выбор этой формулы тем соображением, что чем длиннее у зависимости левая часть, тем меньше её практическая ценность.

3.3. Страница

Задача представляет собой написание новой страницы в виде React-компонента типа NextPage, которая будет доступна по URL-адресу /reports/charts. В разрабатываемом приложении используется специальный тип страниц NextPageWithLayout, предоставляющий возмож-

ность указать функцию разметки. В нашем случае эта функция обрабатывает содержимое страницы в контекст `TaskContext`. Такой подход рекомендован в документации `Next.js` [7].

3.4. Контекст

При разработке страницы использовался контекст — `TaskContext`, содержащий информацию о текущей задаче и выбранные фильтры. Использование контекста помогло избежать дублирования кода и лишних запросов к `graphql API` при переключении между страницами.

3.5. Жизненный цикл

В компоненте страницы используются два вызова функций-хуков: `useTaskContext` и `useQuery`

```
1 const { taskID, dependenciesFilter, setDependenciesFilter } =  
2   useTaskContext();  
3  
4 const { loading, data, error } = useQuery(  
5   getPieChartData,  
6   getPieChartDataVariables  
7   >(GET_PIE_CHART_DATA, { variables: { taskID } }));
```

Листинг 1: Функции-хуки в компоненте `ReportsCharts`

Хук `useTaskContext` — это функция, которая получает состояние контекста `TaskContext` или показывает ошибку в случае отсутствия провайдера контекста в дереве предков текущего компонента. Хук `useQuery` — это функция из библиотеки `Apollo`, предназначенная для выполнения запроса к `graphql API`. При первой отрисовке компонента объект `data` еще не определен, так как запрос не был совершен. В этом случае булев флаг `loading` равен `true`, и мы показываем сообщение о загрузке страницы.

3.6. Диаграммы

Для визуального представления значимости различных атрибутов в найденных зависимостях было решено использовать круговые диаграммы, которые доступны в библиотеке `react-chartjs-2`. Однако при большом количестве атрибутов диаграмма может стать перегружена так, что взаимодействовать с ней станет невозможно. Для решения этой проблемы был разработан компонент `LayeredChart`, который разбивает содержимое на слои, ограничивая количество отображаемых секторов в диаграмме и представляя непоместившиеся атрибуты сектором с названием «Other». Был учтен опыт ранней реализации, и выполнена декомпозиция основного компонента диаграммы на компоненты `ChartControls` и `Chart` так, что параметры компонента пробрасываются не более, чем на уровень.

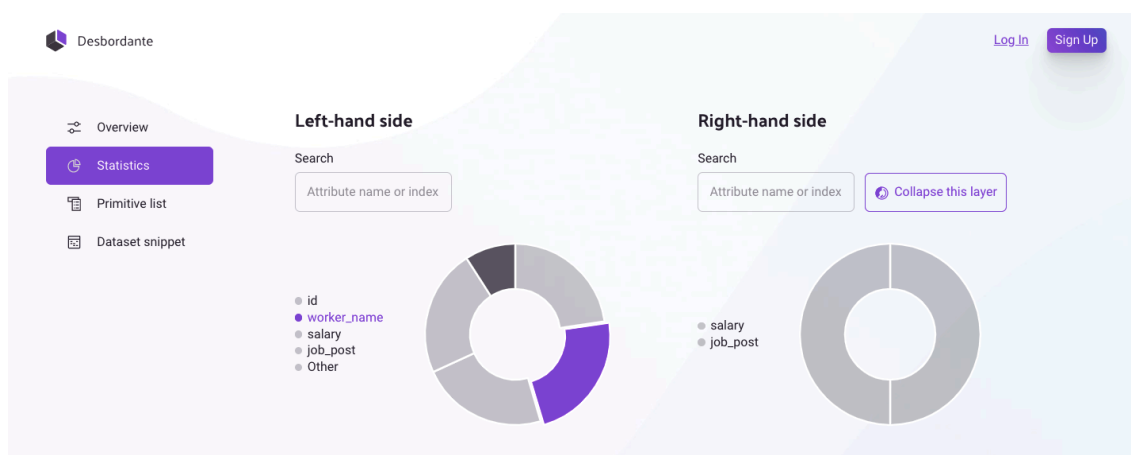


Рис. 2: Страница с визуализацией результатов поиска примитива “функциональная зависимость”

3.6.1. Параметры компонента

Компонент `LayeredChart` имеет следующий набор параметров.

- `attributes` — массив атрибутов с подсчитанным весом
- `selectedAttributeIndices`, `setSelectedAttributeIndices` — выбранные пользователем атрибуты и метод, вызываемый при изменении выбора

- `maxItemsShown` — максимальное количество отображаемых секторов на диаграмме
- `title` — заголовок

3.6.2. Состояние и жизненный цикл компонента

Состояние компонента определяется с помощью React-хуков `useState` и состоит из глубины просмотра диаграммы, поисковой строки, выбранного сектора и массива атрибутов в текущем слое.

Изменение глубины просмотра происходит по клику на сектор «Other» или кнопку «Collapse». Механизм фильтрации атрибутов реализован в хуке `useEffect` с помощью указания зависимостей, при изменении которых должна происходить повторная отрисовка компонента. Описания элементов управления вынесено в отдельный компонент `ChartControls`, а сама диаграмма из библиотеки `react-chartjs-2` интегрирована в многоуровневую диаграмму `LayeredChart` с помощью библиотечного React-компонента `Chart`.

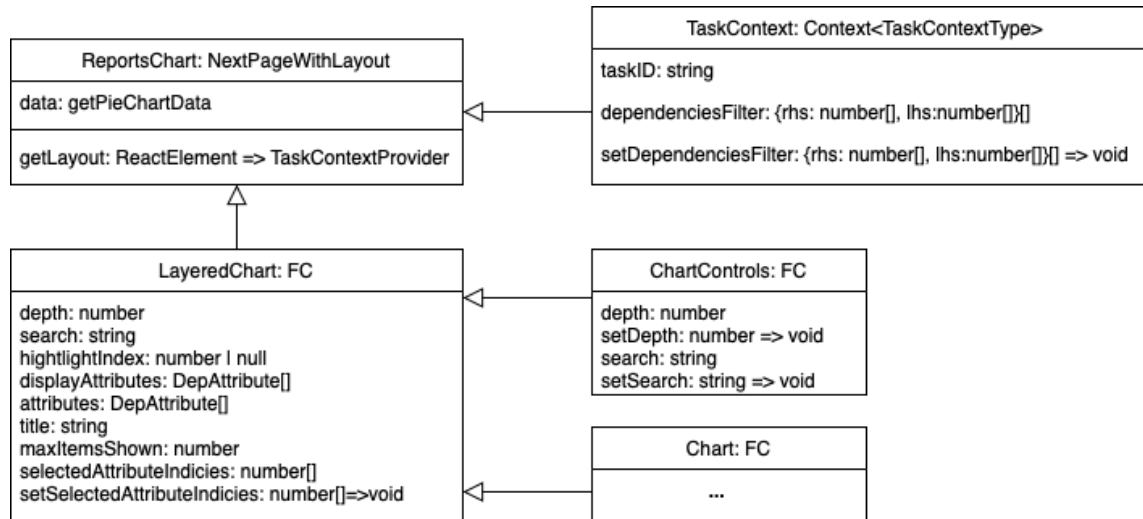


Рис. 3: Диаграмма компонентов, используемых в разработанной странице

4. Тестирование

Было произведено ручное тестирование приложения. Проверена работоспособность диаграмм атрибутов. Проверен функционал поиска атрибутов на диаграмме и выбора атрибутов для фильтрации на других страницах. Проверена отзывчивость верстки при изменении размера экрана.

Тестирование проходило на задачах следующей конфигурации.

- поиск функциональных зависимостей был произведен на наборе табличных данных с 1281732 строками и 10 колонками с помощью алгоритма Руго, было найдено 54 зависимости, и левая, и правая диаграмма представляли собой два уровня с секторами размера, вычисленном на стороне сервера;
- поиск условных функциональных зависимостей был произведен на наборе табличных данных с 3 колонками и 10 строками с помощью алгоритма STane, было найдено 60 зависимостей, причем диаграммы представляли собой 3 сектора равного размера, поскольку вычисленный на сервере вес атрибутов был одинаков.

Заключение

В ходе данной работы были выполнены следующие задачи:

- выполнена адаптивная верстка страницы
- реализован компонент многоуровневой диаграммы и элементов управления
- реализовано взаимодействие с серверной частью приложения
- проведена проверка работоспособности приложения

Ссылка на GitHub-репозиторий <https://github.com/vs9h/Desbordante/tree/webapp-redesign> (имя пользователя — iliya-b).

Список литературы

- [1] Abedjan Ziawasch, Golab Lukasz, Naumann Felix. Profiling Relational Data: A Survey // [The VLDB Journal](#). — 2015. — aug. — Vol. 24, no. 4. — P. 557–581. — URL: <https://doi.org/10.1007/s00778-015-0389-y>.
- [2] Ayerst Jeremy. react-chartjs-2 documentation. — 2022. — accessed: 2022-09-22. URL: <https://react-chartjs-2.js.org>.
- [3] Ilya Barutkin. Разработка клиентской части веб-приложения Desbordante. — 2022. — accessed: 2022-09-22. URL: <https://github.com/Mstrutov/Desbordante/blob/main/docs/papers/Frontend%20-%20Ilya%20Barutkin%20-%202021%20spring.pdf>.
- [4] Kirill Stupakov. Разработка клиентской части веб-приложения Desbordante. — 2022. — accessed: 2022-09-22. URL: <https://github.com/Mstrutov/Desbordante/blob/main/docs/papers/Frontend%20-%20Kirill%20Stupakov%20-%202021%20autumn.pdf>.
- [5] M. Strutovskiy N. Bobrov K. Smirnov, Chernishev G. [Desbordante: a Framework for Exploring Limits of Dependency Discovery Algorithms](#) // 2021 29th Conference of Open Innovations Association (FRUCT). — 2021. — P. 344–354.
- [6] Papenbrock Thorsten. Data profiling - efficient discovery of dependencies : Ph.D. thesis / Thorsten Papenbrock. — 2017. — 01. — P. 99–100.
- [7] Vercel Inc. Next.js Layout Documentation. — 2022. — accessed: 2022-09-22. URL: <https://nextjs.org/docs/basic-features/layouts#per-page-layouts>.